

## MAE5911/IME: Fundamentos de Estatística e Machine Learning. Prof.: Alexandre Galvão Patriota

**Questão 01:** Considere uma amostra aleatória  $(Y_1, X_1), \dots, (Y_n, X_n)$  de  $(Y, X)$  tal que a distribuição condicional  $Y | X = x \sim \mathcal{N}(\mu_\theta(x), \sigma_\theta^2(x))$ , e suponha que a distribuição de  $X$  não contém informação sobre os parâmetros.

**Ítem 1.1** Apresente uma **rede neural** que modele o **quantil de ordem 75%** (terceiro quartil) da distribuição condicional  $Y | X = x$ . O código deve ser generalizável para qualquer quantil.

**Ítem 1.2** Mostre a aplicação do método nos seguintes dados simulados em R:

```
set.seed(32)

n = 1000

x = sort(runif(n, -4, 4))

y = 3 / (3 + 2|x|^3) + e^{-x^2} + cos(x) sin(x) + 0.3 ε,    ε ~ N(0, 1)
```

Sugestão: reescreva a esperança e variância condicionais em termos do quantil e construa a função de verossimilhança apropriada.

### Resposta para Ítem 1.1

#### Encontrando a função de verossimilhança em termos do quantil condicional

Seja

$$Y | X = x \sim \mathcal{N}(\mu(x), \sigma^2(x)). \quad (1)$$

Para um nível de quantil  $q \in (0, 1)$ , definimos o quantil condicional  $Q_q(x)$  de  $Y | X = x$  como o valor  $t$  que satisfaz

$$\mathbb{P}(Y \leq t | X = x) = q. \quad (2)$$

No caso da Normal, o quantil condicional pode ser escrito em termos da média e do desvio-padrão:

$$Q_q(x) = \mu(x) + \sigma(x) z_q, \quad (3)$$

em que  $z_q = \Phi^{-1}(q)$  é o quantil de ordem  $q$  da Normal padrão  $\mathcal{N}(0, 1)$  e  $\Phi$  denota a sua função de distribuição acumulada.

Podemos, então, reparametrizar o modelo em função de  $Q_q(x)$ , escrevendo

$$\mu(x) = Q_q(x) - \sigma(x) z_q. \quad (4)$$

#### 0.1 Verossimilhança em termos do quantil

A densidade de  $Y | X = x$  é

$$f(y | x) = \frac{1}{\sqrt{2\pi} \sigma(x)} \exp \left\{ -\frac{(y - \mu(x))^2}{2\sigma^2(x)} \right\}. \quad (5)$$

Substituindo  $\mu(x) = Q_q(x) - \sigma(x)z_q$ , obtemos

$$f(y | x) = \frac{1}{\sqrt{2\pi}\sigma(x)} \exp\left\{-\frac{(y - Q_q(x) + \sigma(x)z_q)^2}{2\sigma^2(x)}\right\}. \quad (6)$$

A log-verossimilhança para uma observação  $(x_i, y_i)$ , desprezando constantes que não dependem de  $Q_q$ , é dada por

$$\ell_i(Q_q, \sigma) = -\log \sigma(x_i) - \frac{(y_i - Q_q(x_i) + \sigma(x_i)z_q)^2}{2\sigma^2(x_i)}. \quad (7)$$

O correspondente negativo da log-verossimilhança (função de perda) é

$$\mathcal{L}_{\text{NLL}} = \sum_{i=1}^n \left[ \log \sigma(x_i) + \frac{(y_i - Q_q(x_i) + \sigma(x_i)z_q)^2}{2\sigma^2(x_i)} \right]. \quad (8)$$

## 0.2 Caso com variância conhecida

Se assumirmos uma variância condicional conhecida e constante,  $\sigma(x) \equiv \sigma_0$ , o termo  $\log \sigma(x_i)$  torna-se constante e pode ser ignorado na minimização. Nesse caso, a perda se reduz a

$$\mathcal{L}_{\text{NLL}} \propto \sum_{i=1}^n (y_i + \sigma_0 z_q - Q_q(x_i))^2. \quad (9)$$

Definindo a variável transformada

$$Z_i = y_i + \sigma_0 z_q, \quad (10)$$

temos

$$Z_i | X_i = x \sim \mathcal{N}(Q_q(x), \sigma_0^2), \quad (11)$$

ou seja,  $Q_q(x)$  é exatamente a *média condicional* de  $Z_i$  dado  $X_i = x$ .

Assim, sob o modelo Normal com variância constante, podemos estimar o quantil condicional  $Q_q(x)$  minimizando um *erro quadrático médio* sobre a variável transformada  $Z_i$ :

$$\mathcal{L}_{\text{MSE-quantil}} = \sum_{i=1}^n (Z_i - Q_q(x_i))^2. \quad (12)$$

## Descrição do experimento e configuração do modelo

### Hiperparâmetros do modelo

### Arquitetura

### Tamanho do modelo

### Treinamento e métricas