

## MAE5911/IME: Fundamentos de Estatística e Machine Learning. Prof.: Alexandre Galvão Patriota

**Questão 01:** Descreva o mecanismo de atenção com múltiplas cabeças (Multi-head Attention). Apresente o desenvolvimento como feito em sala, considerando a versão “mascarada”, para identificar médias ponderadas dinamicamente.

O mecanismo de atenção é o que transforma representação semântica de tokens em representação contextualizada, garantindo que os tokens sejam reinterpretados de acordo com o contexto em que é referido. O mecanismo consiste em durante o treino aprender as matrizes  $W_Q$  e  $W_K$  que representam parâmetros de *query*, o que este token procura, e *key*, o que este token oferece, tais que

$$Q_i = x_i * W_Q$$

$$K_i = x_i * W_K,$$

no qual, durante o teste, o embedding  $x$  de cada token é redefinido para um novo valor utilizando a fórmula

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)V = \sum_j A_{ij} V_j$$

na qual  $M$  é a máscara que apenas atribui contribuição não nula para tokens em relação a si mesmo e aos tokens predecessores, garantindo uma análise causal de contexto e  $V$  é a estatística suficiente sobre a qual tomamos a expectativa, também calculado via matriz de parâmetros  $W_V$ , tal que  $V_i = x_i * W_V$ . O resultado final é a matriz Attention, que tem dimensão  $n \times d_{model}$ , para  $n$  tokens e dimensão do embedding  $d_{model}$ , no modelo com uma cabeça.

Para o modelo com multiplas cabeças, o *Multi-head Attention*, a dimensão do embedding é dividida em  $h$  cabeças, cada uma com dimensão  $d_k = d_{model}/h$ . Cada cabeça aprende suas próprias matrizes de parâmetros  $W_Q^{(i)}$ ,  $W_K^{(i)}$  e  $W_V^{(i)}$ , para  $i = 1, \dots, h$ . O mecanismo de atenção é aplicado separadamente para cada cabeça, resultando em  $h$  matrizes de atenção distintas.

Este modelo tem a vantagem de reduzir a dimensionalidade do embedding e permitir a paralelização do cálculo da matriz de atenção, além de permitir que cada cabeça foque em diferentes partes da sequência de entrada  $x$ , analisando separadamente diferentes aspectos de relacionamento entre tokens, como por exemplo, semântica, sintaxe, ou interdependências. Essas matrizes são então concatenadas e projetadas de volta para a dimensão original do embedding usando uma matriz de projeção de parâmetros adicional  $W_O$ , que combina as matrizes de atenção com pesos diferentes, adicionando uma camada adicional de refinamento do contexto, podendo adicionalmente ser utilizada para reduzir a dimensionalidade do embedding. A fórmula do modelo com multi-head attention é:

$$\text{MultiHead}(Q, K, V) = \text{Concat}\left(\text{Attention}(QW_1^Q, KW_1^K, VW_1^V), \dots, \text{Attention}(QW_h^Q, KW_h^K, VW_h^V)\right)W^O.$$

**Exemplo do cálculo de *multi-head attention*, partindo dos seguintes blocos  $W_Q$ ,  $W_K$  e  $W_V$  de parâmetros de atenção treinados, e  $W_O = I_4$  neste exemplo por simplicidade, para  $h = 2$ :**

Head 1

$$W_Q^{(1)} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, W_K^{(1)} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, W_V^{(1)} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$$

Head 2

$$W_Q^{(2)} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}, W_K^{(2)} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}, W_V^{(2)} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Considere um prompt com  $n = 3$  tokens:

(Life, is, awesome)

Cada token é representado por um embedding de dimensão  $d_{\text{model}} = 4$ . Para fins ilustrativos consideramos a seguinte matriz de embeddings:

$$X = \begin{bmatrix} \text{Life} \\ \text{is} \\ \text{awesome} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{bmatrix} \in \mathbb{R}^{3 \times 4}.$$

Cálculo das projeções Q, K, V para cada token:

$$Q^{(i)} = XW_Q^{(i)}, \quad K^{(i)} = XW_K^{(i)}, \quad V^{(i)} = XW_V^{(i)},$$

Head 1

$$Q^{(1)} = \begin{bmatrix} 2 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad K^{(1)} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \\ 1 & 3 \end{bmatrix}, \quad V^{(1)} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \\ 1 & 2 \end{bmatrix}$$

Head 2

$$Q^{(2)} = \begin{bmatrix} 0 & 2 \\ 1 & 1 \\ 2 & 1 \end{bmatrix}, \quad K^{(2)} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 3 & 1 \end{bmatrix}, \quad V^{(2)} = \begin{bmatrix} 1 & 1 \\ 2 & 0 \\ 1 & 2 \end{bmatrix}$$

Calculamos agora, para  $d_k = d_{\text{model}}/h = 2$ :

$$S^{(i)} = \frac{Q^{(i)}K^{(i)\top}}{\sqrt{d_k}}$$

Head 1

$$S^{(1)} = \frac{1}{\sqrt{2}} \begin{bmatrix} 4 & 2 & 2 \\ 3 & 2 & 4 \\ 4 & 3 & 7 \end{bmatrix}$$

Head 2

$$S^{(2)} = \frac{1}{\sqrt{2}} \begin{bmatrix} 2 & 4 & 2 \\ 2 & 3 & 4 \\ 3 & 4 & 7 \end{bmatrix}$$

Aplicamos em seguida a máscara causal, o que impede que o token  $t$  seja co-relacionado com tokens em posições subsequentes (futuras)  $j > t$ , exatamente igual ocorre no treinamento. Os scores mascarados são obtidos por:

$$\tilde{S}^{(i)} = S^{(i)} + M, \quad M = \begin{bmatrix} 0 & -\infty & -\infty \\ 0 & 0 & -\infty \\ 0 & 0 & 0 \end{bmatrix},$$

Note que a máscara zera as probabilidades das posições não causais:

$$\tilde{S}_{1,:}^{(1)} = (s_{11}, -\infty, -\infty) \implies \text{softmax}(\tilde{S}_{1,:}^{(1)}) = \frac{(e^{s_{11}}, e^{-\infty}, e^{-\infty})}{e^{s_{11}} + e^{-\infty} + e^{-\infty}} = (1, 0, 0),$$

Aplicando a função softmax linha a linha aos scores mascarados, obtemos as matrizes  $A^{(1)}$  e  $A^{(2)}$ .

Head 1

$$A^{(1)} = \begin{bmatrix} 1.000 & 0.000 & 0.000 \\ 0.670 & 0.330 & 0.000 \\ 0.102 & 0.050 & 0.848 \end{bmatrix}$$

Head 2

$$A^{(2)} = \begin{bmatrix} 1.000 & 0.000 & 0.000 \\ 0.330 & 0.670 & 0.000 \\ 0.050 & 0.102 & 0.848 \end{bmatrix}$$

A saída da cabeça  $i$  é

$$\text{head}_i = A^{(i)}V^{(i)} \in \mathbb{R}^{3 \times 2}.$$

Head 1

$$A^{(1)}V^{(1)} \simeq \begin{bmatrix} 2.000 & 1.000 \\ 1.670 & 1.330 \\ 1.102 & 1.898 \end{bmatrix}$$

Head 2

$$A^{(2)}V^{(2)} \simeq \begin{bmatrix} 1.000 & 1.000 \\ 1.670 & 0.330 \\ 1.102 & 1.747 \end{bmatrix}$$

Considerando, por simplicidade, a projeção de saída como a identidade,

$$W^O = I_4,$$

a saída final do bloco de *multi-head attention* é

$$\text{MultiHead}(Q, K, V) = \text{Concat}(H^{(1)} | H^{(2)})W_O \in \mathbb{R}^{3 \times 4}.$$

Multi-Head Attention

$$\text{MultiHead}(Q, K, V) = \begin{bmatrix} 2.000 & 1.000 & 1.000 & 1.000 \\ 1.670 & 1.330 & 1.670 & 0.330 \\ 1.102 & 1.898 & 1.102 & 1.747 \end{bmatrix} \begin{bmatrix} 1.000 & 0.000 & 0.000 & 0.000 \\ 0.000 & 1.000 & 0.000 & 0.000 \\ 0.000 & 0.000 & 1.000 & 0.000 \\ 0.000 & 0.000 & 0.000 & 1.000 \end{bmatrix}$$

**Resultado final:**

Multi-Head Attention (novos *embeddings* contextualizados)

$$\text{Attention}(Q, K, V) = \begin{bmatrix} \text{Life} \\ \text{is} \\ \text{awesome} \end{bmatrix} = \begin{bmatrix} 2.000 & 1.000 & 1.000 & 1.000 \\ 1.670 & 1.330 & 1.670 & 0.330 \\ 1.102 & 1.898 & 1.102 & 1.747 \end{bmatrix}$$

```

1 # -----
2 # Cada camada N da rede neural receberá um módulo de atenção multi-cabeças definido da seguinte forma:
3 #
4 self$MM <- torch::nn_module_list(lapply(1:N_Layers,
5   function(x) torch::nn_multihead_attention(
6     n_embd,           # d_model: dimensão do vetores de embedding
7     N_Head,           # h: número de cabeças
8     dropout = p0,    # técnica para reduzir o overfitting
9     batch_first = TRUE))) # informa a disposição dos dados à biblioteca torch

```

Listing 1: **Definição** dos blocos de multi-head attention treináveis

```

1 # -----
2 # Cria uma matriz TxT, sendo T = número de tokens na sequência de entrada
3 # Garante que será tratado no mesmo device que X (CPU ou GPU) para que eles possam ser operados juntos
4 # Aplica 1 à diagonal superior, transforma 1 em booleano TRUE para que a biblioteca torch saiba quais
5 # posições precisam ser mascaradas
6 #
7 wei <- torch::torch_triu(
8   torch::torch_ones(T, T, device = x$device),
9   diagonal = 1)$to(dtype = torch::torch_bool())

```

Listing 2: **Definição** da Máscara causal

```

1 for (j in 1:self$N) {
2
3   # -----
4   # 1) Pré-normalização (LayerNorm)
5   # Normalização dos embeddings, já que todos embeddings interagirão com todos os outros.
6   # A normalização não altera a informação e estabiliza o treinamento.
7   #

```

```

8 QKV <- self$scale1[[j]](output)
9
10 # -----
11 # 2) Chamada da função Multi-Head Self-Attention mascarada do torch que calcula Q, K e V internamente a
12 # partir de QKV.
13 # -----
14 attn_out <- self$MM[[j]](
15   query      = QKV,      # Input para o cálculo de Q
16   key        = QKV,      # Input para o cálculo de K
17   value      = QKV,      # Input para o cálculo de V
18   attn_mask  = wei,      # Máscara causal
19   need_weights = FALSE # Dispensa o retorno dos pesos utilizados no cálculo da média ponderada
20 )[[1]]                      # Guarda apenas o resultado da média ponderada, mas não os pesos
21
22 # -----
23 # 3) Conexão residual após atenção
24 # Mantém a informação original dos embeddings e evita que a transformação da atenção distorça
25 # excessivamente a representação.
26 # Estabiliza o fluxo do gradiente.
27 # -----
28 output <- output + attn_out
29
30 # -----
31 # 4) Feed-Forward Network + residual
32 # Aplicação de uma MLP ponto-a-ponto em cada token individualmente, capturando relações não lineares
33 # permitindo que a rede aprenda padrões complexos.
34 # Mantendo o resíduo e aplicando a normalização para estabilizar a operação.
35 # -----
36 output <- output + self$FFN[[j]]( self$scale2[[j]](output) )
37 }

```

Listing 3: Cálculo da atenção multi-cabeças mascarada em cada camada

**Questão 02:** Treine um modelo de linguagem com dimensão embedding de 128, duas camadas e duas cabeças para os dados de Shakespeare.

## Descrição do experimento e configuração do modelo

### Corpus utilizado

O modelo foi treinado sobre um corpus textual extraído da edição completa das obras de William Shakespeare disponibilizada pelo *Project Gutenberg*, um repositório digital que distribui gratuitamente obras que já se encontram em domínio público, contendo todo o conteúdo produzido pelo autor: peças teatrais, poemas narrativos, sonetos, trechos introdutórios e notas editoriais presentes na edição digital, com aproximadamente 5,4 milhões de caracteres.

**DUKE.**  
*So that, from point to point, now have you heard  
 The fundamental reasons of this war,  
 Whose great decision hath much blood let forth,  
 And more thirsts after.*

**FIRST LORD.**  
*Holy seems the quarrel  
 Upon your Grace's part; black and fearful  
 On the opposer.*

**DUKE.**  
*Therefore we marvel much our cousin France  
 Would, in so just a business, shut his bosom  
 Against our borrowing prayers.*

**MENECRATES.**  
*We, ignorant of ourselves,  
 Beg often our own harms, which the wise powers  
 Deny us for our good; so find we profit  
 By losing of our prayers.*

**POMPEY.**  
*I shall do well.  
 The people love me, and the sea is mine;  
 My powers are crescent, and my auguring hope  
 Says it will come to th' full. Mark Antony  
 In Egypt sits at dinner, and will make  
 No wars without doors. Caesar gets money where  
 He loses hearts. Lepidus flatters both,  
 Of both is flattered; but he neither loves  
 Nor either cares for him.*

Figura 1: Trechos do corpus utilizado no experimento, provenientes da obra completa de Shakespeare disponibilizado pelo Projeto Gutenberg.

## Vocabulário extraído do corpus

O modelo foi treinado no regime *character-level*, o primeiro passo consistiu em extrair todos os caracteres distintos presentes no arquivo `Shakespeare.txt`. Inclui letras maiúsculas e minúsculas, dígitos, pontuação, símbolos especiais, acentos, quebras de linha e espaços.

O vocabulário final contém **109 tokens**, sendo o primeiro reservado para o símbolo especial `<PAD>` utilizado em operações internas. Segue o conjunto de caracteres identificados:

[1]	"<PAD>"	""	"\t"	"\n"	"\r"	" "	"_"	"_"	"_"	","	";"	";"
[13]	"!"	"?"	".."	"..."	"'."	"‘."	"‘‘."	"‘‘‘."	"‘‘‘‘."	"‘‘‘‘‘."	"‘‘‘‘‘‘."	"[“
[25]	"]"	"*"	"/"	"&"	"#"	"%"	"●"	"\$"	"Ø"	"1"	"2"	"3"
[37]	"4"	"5"	"6"	"7"	"8"	"9"	"a"	"A"	"à"	"À"	"â"	"æ"
[49]	"Æ"	"b"	"B"	"c"	"C"	"ç"	"Ç"	"d"	"D"	"e"	"E"	"é"
[61]	"É"	"è"	"ê"	"ë"	"ƒ"	"F"	"g"	"G"	"h"	"H"	"i"	"I"
[73]	"î"	"j"	"J"	"k"	"K"	"l"	"L"	"m"	"M"	"n"	"N"	"o"
[85]	"0"	"æ"	"p"	"P"	"q"	"Q"	"r"	"R"	"s"	"S"	"t"	"T"
[97]	"™"	"u"	"U"	"v"	"V"	"w"	"W"	"x"	"X"	"y"	"Y"	"z"
[109]	"Z"											

Figura 2: Vocabulário extraído no corpus utilizado (obra completa de Shakespeare).

## Hiperparâmetros do modelo

Os hiperparâmetros utilizados no modelo são:

Tabela 1: Hiperparâmetros utilizados no modelo GPT treinado.

Hiperparâmetro	Valor	Descrição
block_size	50	contexto máximo (janela do attention).
n_embd	128	dimensão dos embeddings.
N_Layers	2	número de blocos Transformer.
N_Head	2	número de cabeças de atenção.
dropout	0.2	regularização.
learning_rate	0.003	taxa de aprendizado.
batch_size	64	tamanho do mini-batch.
epochs	1200	número total de épocas.

O tamanho de contexto (`block_size = 50`) limita o alcance da atenção foi ajustado empiricamente para conseguir captar o estilo do texto e ao mesmo tempo ser viável para ser treinado em hardware pessoal. A dimensão dos vetores de embedding (`n_embd = 128`) é significativo, mas combinada ao número reduzido de camadas e a utilização de multiplas cabeças de atenção (`N_Layers = 2`, `N_Head = 2`), mantém o modelo ágil e compacto, suficiente para capturar regularidades sintáticas e estilísticas do texto. O dropout (0.2) fornece regularização. A taxa de aprendizado escolhida (0.003) foi ajustada empiricamente.

## Arquitetura e fluxo do modelo

A arquitetura utilizada neste trabalho segue o padrão dos modelos GPT do tipo *decoder-only*, cujo fluxo computacional está ilustrado na Fig. 3. O processamento inicia-se pela soma entre o embedding dos tokens e o embedding posicional aprendido, resultando em uma representação contínua que preserva a ordem sequencial do texto. Em seguida, cada camada Transformer aplica uma normalização prévia (*LayerNorm*) seguida de um bloco de autoattenção multi-cabeças mascarada, garantindo o comportamento autoregressivo: o modelo só pode utilizar informações de tokens passados para prever o próximo token.

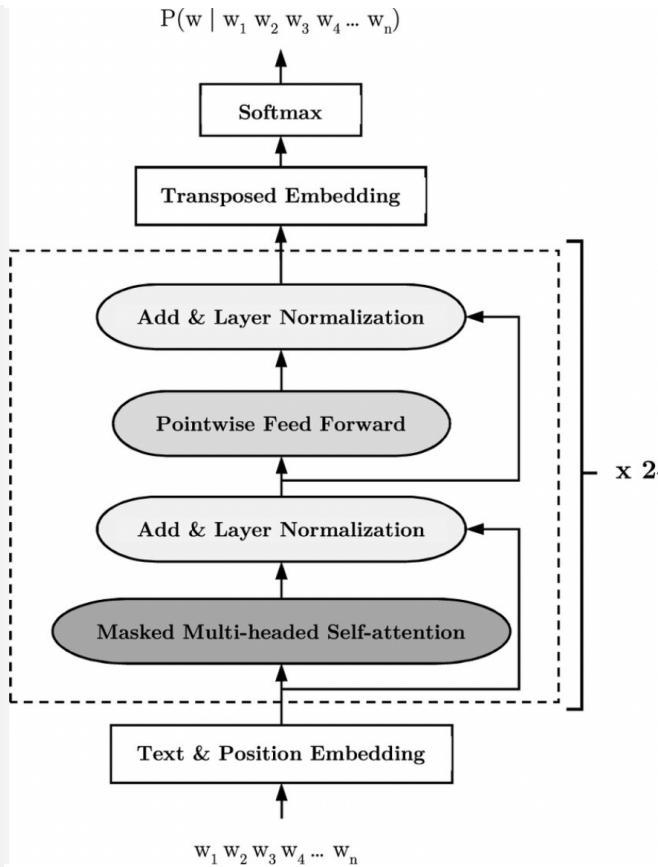


Figura 3: Arquitetura geral do modelo GPT utilizado no experimento.

O resultado da atenção é então somado à entrada original por meio de uma conexão residual, estabilizando o fluxo de gradientes. Após isso, uma nova normalização é aplicada antes do bloco *feed-forward* ponto-a-ponto, responsável por expandir e recomprimir a dimensionalidade interna, permitindo ao modelo capturar não-linearidades locais. Esse bloco também é seguido por uma conexão residual, completando a estrutura *pré-norm* típica de arquiteturas modernas de Transformers. Ao final das camadas empilhadas (2) uma projeção linear — equivalente ao uso do embedding transposto — produz os logits sobre o vocabulário, posteriormente convertidos em probabilidades via *softmax*, que indica o próximo token mais provável.

### Tamanho do modelo

O modelo GPT implementado apresenta um total de **418 866 parâmetros** treináveis, distribuídos entre embeddings, projeções lineares das camadas de atenção, normalizações e redes feed-forward. A Tabela 2 apresenta o detalhamento dos tensores de parâmetros que compõem o modelo.

Parâmetro	Dimensão	Nº de parâmetros
wpe.weight	50 × 128	6 400
wte.weight	109 × 128	13 952
MM.0.in_proj_weight	384 × 128	49 152
MM.0.in_proj_bias	384	384
MM.0.out_proj_weight	128 × 128	16 384
MM.0.out_proj_bias	128	128
MM.1.in_proj_weight	384 × 128	49 152
MM.1.in_proj_bias	384	384
MM.1.out_proj_weight	128 × 128	16 384
MM.1.out_proj_bias	128	128
scale1.{0,1}.weight	128	128 + 128
scale1.{0,1}.bias	128	128 + 128
scale2.{0,1}.weight	128	128 + 128
scale2.{0,1}.bias	128	128 + 128
scale3.weight	128	128
scale3.bias	128	128
FFN.0.{0,2}.weight	512 × 128	65 536 + 65 536
FFN.0.{0,2}.bias	512	512 + 128
FFN.1.{0,2}.weight	512 × 128	65 536 + 65 536
FFN.1.{0,2}.bias	512	512 + 128
ln_f.weight	109 × 128	13 952
<b>Total</b>	—	<b>418 866</b>

Tabela 2: Parâmetros treináveis do modelo GPT utilizado no experimento.

### Treinamento e métricas

No treinamento, foi utilizada a função de perda *cross-entropy*, computada entre os logits produzidos pelo modelo e os caracteres-alvo da sequência. A cada época, registramos tanto a perda de treino quanto a de teste, permitindo acompanhar a evolução do aprendizado e o possível surgimento de sobreajuste.

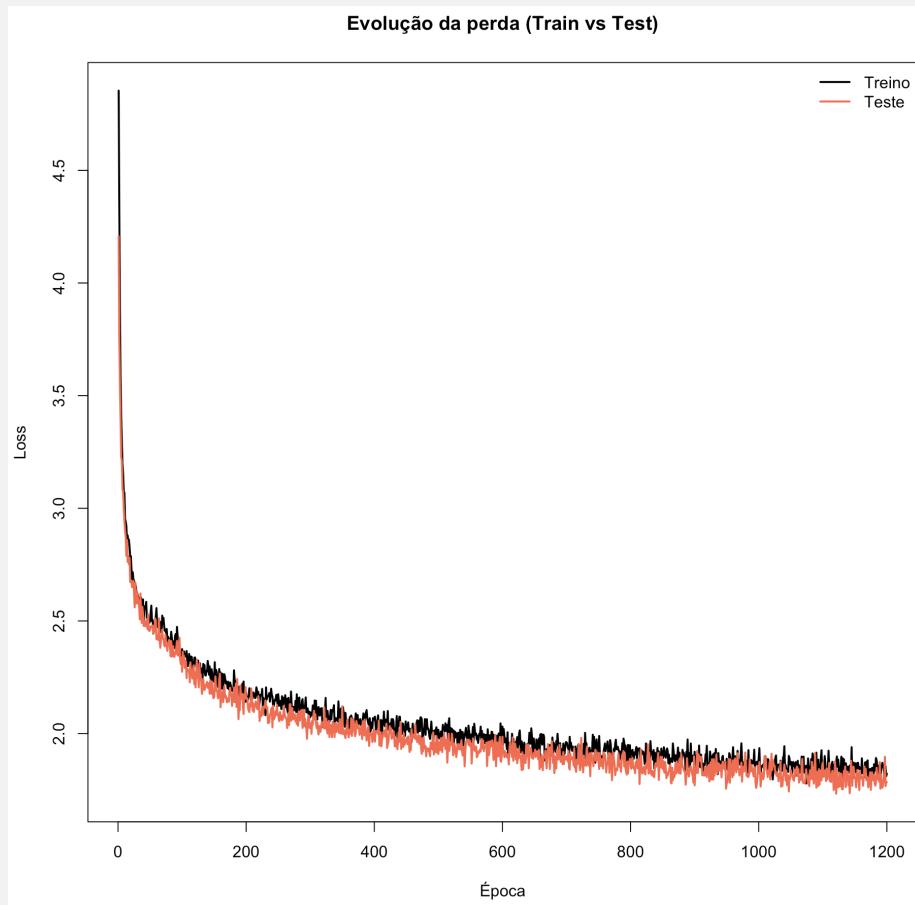


Figura 4: Evolução da função de perda durante o treinamento: comparação entre as curvas de treino e de teste ao longo das 1200 épocas.

As curvas de perda apresentaram comportamento regular ao longo das épocas: as perdas de treino e de teste permaneceram próximas, decrescendo de forma suave sem indícios de divergência. Essa proximidade entre as curvas indica ausência de sobreajuste, sugerindo que o modelo conseguiu aprender padrões relevantes do corpus sem memorizar o conjunto de treinamento. Além disso, a estabilidade observada nas últimas épocas reflete um processo de otimização bem-sucedido.

O valor final da perda obtido após 1200 épocas foi de aproximadamente 1.82 para o conjunto de treino e 1.78 para o conjunto de teste.

## Resultado

Os resultados obtidos mostram que o modelo, apesar de compacto, aprendeu *padrões estatísticos* presentes no inglês shakespeariano, como a distribuição típica de comprimentos de palavras, certa cadência rítmica, alternância entre diálogos e rubricas, além da reprodução aproximada de construções sintáticas características do período.

Entretanto, o texto gerado permanece semanticamente incoerente, apresentando repetições excessivas e sentenças circulares. Esse comportamento é esperado para um modelo de pequena escala: ele captura a superfície do estilo, mas não reproduz a coerência e os encadeamentos semânticos ao longo do texto. O processo de tokenização mais robusto pode contribuir significativamente para melhorar a coerência do texto.

Anter to my lord, and to the with and the world with that to  
they have a man they seen of the canother with a shall he  
have the with a sons to the can the wittle the would the will  
have the come to the world  
To the can too to the world to me the coment too the with the  
comman the will have the come to my like the with the would  
the consef the with to the come an the words,  
And the words, an a shall the coment on the can to that the  
can the will to me the can a man the come and when they  
senders.  
[\_Exeunt.\_]  
PETHARD.  
The he will they have they have with the confather the cannot  
the will the come the word and with the can and that which the

SENE ONT. A me that the so a course that to the came and to  
thee, the compe thee, and me seat the come that the so a me,  
and to me to the come the so to man that to make the come,  
that the word a come a so the see the see a man the come  
the course and the so to the see and me so the see a praint.

SENE.  
So me, the we the come to the sear a part the some a prath,  
the with a proust and that the can the some a mand to the  
counted the some, the counders a me see that that me see to  
that to man to thee with to that my so the came and that thee  
word,  
Then, and with to me,  
And me, the so all we with a cand man a part the see, and  
that and with a me to me the camine the seak to the will make  
to to making too a me so that that me so a can the so to me  
to man the can the so a come the so the come a part and the  
see the course the so a care, and the so the come a me,

Figura 5: Trechos do texto gerado pelo modelo treinado.

O experimento valida a implementação completa de um Transformer do tipo *decoder-only*, confirmando que mesmo arquiteturas reduzidas conseguem capturar características linguísticas relevantes quando treinadas sobre um corpus particular. O modelo foi capaz de replicar com consistência o *ritmo*, o *fluxo* e a *forma* geral do estilo shakespeariano.

**Questão 03:** Repita o item anterior sem o mecanismo de atenção (com múltiplas cabeças) e descreva o que ocorre no treinamento.