

MAE5911/IME: Fundamentos de Estatística e Machine Learning. Prof.: Alexandre Galvão Patriota

Questão 01: Descreva o mecanismo de atenção com múltiplas cabeças (Multi-head Attention). Apresente o desenvolvimento como feito em sala, considerando a versão “mascarada”, para identificar médias ponderadas dinamicamente.

O mecanismo de atenção é o que transforma representação semântica de tokens em representação contextualizada, garantindo que os tokens sejam reinterpretados de acordo com o contexto em que é referido. O mecanismo consiste em durante o treino aprender as matrizes W_Q e W_K que representam parâmetros de *query*, o que este token procura, e *key*, o que este token oferece, tais que

$$Q_i = x_i * W_Q$$

$$K_i = x_i * W_K,$$

no qual, durante o teste, o embedding x de cada token é redefinido para um novo valor utilizando a fórmula

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right) V = \sum_j A_{ij} V_j$$

na qual M é a máscara que apenas atribui contribuição não nula para tokens em relação a si mesmo e aos tokens predecessores, garantindo uma análise causal de contexto e V é a estatística suficiente sobre a qual tomamos a expectativa, também calculado via matriz de parâmetros W_V , tal que $V_i = x_i * W_V$. O resultado final é a matriz *Attention*, que tem dimensão $n \times d_{model}$, para n tokens e dimensão do embedding d_{model} , no modelo com uma cabeça.

Para o modelo com multiplas cabeças, o *Multi-head Attention*, a dimensão do embedding é dividida em h cabeças, cada uma com dimensão $d_k = d_{model}/h$. Cada cabeça aprende suas próprias matrizes de parâmetros $W_Q^{(i)}$, $W_K^{(i)}$ e $W_V^{(i)}$, para $i = 1, \dots, h$. O mecanismo de atenção é aplicado separadamente para cada cabeça, resultando em h matrizes de atenção distintas.

Este modelo tem a vantagem de reduzir a dimensionalidade do embedding e permitir a paralelização do cálculo da matriz de atenção, além de permitir que cada cabeça foque em diferentes partes da sequência de entrada x , analisando separadamente diferentes aspectos de relacionamento entre tokens, como por exemplo, semântica, sintaxe, ou interdependências. Essas matrizes são então concatenadas e projetadas de volta para a dimensão original do embedding usando uma matriz de projeção de parâmetros adicional W_O , que combina as matrizes de atenção com pesos diferentes, adicionando uma camada adicional de refinamento do contexto, podendo adicionalmente ser utilizada para reduzir a dimensionalidade do embedding. A fórmula do modelo com multi-head attention é:

$$\text{MultiHead}(Q, K, V) = \text{Concat}\left(\text{Attention}(QW_1^Q, KW_1^K, VW_1^V), \dots, \text{Attention}(QW_h^Q, KW_h^K, VW_h^V)\right) W^O.$$

Exemplo do cálculo de *multi-head attention*, partindo dos seguintes blocos W_Q , W_K e W_V de parâmetros de atenção treinados, e $W_O = I_4$ neste exemplo por simplicidade, para $h = 2$:

Head 1	Head 2
$W_Q^{(1)} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, W_K^{(1)} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, W_V^{(1)} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \\ 0 & 1 \end{bmatrix}$	$W_Q^{(2)} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}, W_K^{(2)} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}, W_V^{(2)} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$

Considere um prompt com $n = 3$ tokens:

(Life, is, awesome)

Cada token é representado por um embedding de dimensão $d_{\text{model}} = 4$. Para fins ilustrativos consideramos a seguinte matriz de embeddings:

$$X = \begin{bmatrix} \text{Life} \\ \text{is} \\ \text{awesome} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{bmatrix} \in \mathbb{R}^{3 \times 4}.$$

Cálculo das projecoes Q, K, V para cada token:

$$Q^{(i)} = XW_Q^{(i)}, \quad K^{(i)} = XW_K^{(i)}, \quad V^{(i)} = XW_V^{(i)},$$

Head 1

$$Q^{(1)} = \begin{bmatrix} 2 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, K^{(1)} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \\ 1 & 3 \end{bmatrix}, V^{(1)} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \\ 1 & 2 \end{bmatrix}$$

Head 2

$$Q^{(2)} = \begin{bmatrix} 0 & 2 \\ 1 & 1 \\ 2 & 1 \end{bmatrix}, K^{(2)} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 3 & 1 \end{bmatrix}, V^{(2)} = \begin{bmatrix} 1 & 1 \\ 2 & 0 \\ 1 & 2 \end{bmatrix}$$

Calculamos agora, para $d_k = d_{\text{model}}/h = 2$:

$$S^{(i)} = \frac{Q^{(i)}K^{(i)\top}}{\sqrt{d_k}}$$

Head 1

$$S^{(1)} = \frac{1}{\sqrt{2}} \begin{bmatrix} 4 & 2 & 2 \\ 3 & 2 & 4 \\ 4 & 3 & 7 \end{bmatrix}$$

Head 2

$$S^{(2)} = \frac{1}{\sqrt{2}} \begin{bmatrix} 2 & 4 & 2 \\ 2 & 3 & 4 \\ 3 & 4 & 7 \end{bmatrix}$$

Aplicamos em seguida a máscara causal, o que impede que o token t seja co-relacionado com tokens em posições subseqüentes (futuras) $j > t$, exatamente igual ocorre no treinamento. Os scores mascarados são obtidos por:

$$\tilde{S}^{(i)} = S^{(i)} + M, \quad M = \begin{bmatrix} 0 & -\infty & -\infty \\ 0 & 0 & -\infty \\ 0 & 0 & 0 \end{bmatrix},$$

Note que a máscara zera as probabilidades das posições não causais:

$$\tilde{S}_{1,:}^{(1)} = (s_{11}, -\infty, -\infty) \implies \text{softmax}(\tilde{S}_{1,:}^{(1)}) = \frac{(e^{s_{11}}, e^{-\infty}, e^{-\infty})}{e^{s_{11}} + e^{-\infty} + e^{-\infty}} = (1, 0, 0),$$

Aplicando a função softmax linha a linha aos scores mascarados, obtemos as matrizes $A^{(1)}$ e $A^{(2)}$.

Head 1

$$A^{(1)} = \begin{bmatrix} 1.000 & 0.000 & 0.000 \\ 0.670 & 0.330 & 0.000 \\ 0.102 & 0.050 & 0.848 \end{bmatrix}$$

Head 2

$$A^{(2)} = \begin{bmatrix} 1.000 & 0.000 & 0.000 \\ 0.330 & 0.670 & 0.000 \\ 0.050 & 0.102 & 0.848 \end{bmatrix}$$

A saída da cabeça i é

$$\text{head}_i = A^{(i)}V^{(i)} \in \mathbb{R}^{3 \times 2}.$$

Head 1

$$A^{(1)}V^{(1)} \simeq \begin{bmatrix} 2.000 & 1.000 \\ 1.670 & 1.330 \\ 1.102 & 1.898 \end{bmatrix}$$

Head 2

$$A^{(2)}V^{(2)} \simeq \begin{bmatrix} 1.000 & 1.000 \\ 1.670 & 0.330 \\ 1.102 & 1.747 \end{bmatrix}$$

Considerando, por simplicidade, a projeção de saída como a identidade,

$$W^O = I_4,$$

a saída final do bloco de *multi-head attention* é

$$\text{MultiHead}(Q, K, V) = \text{Concat}(H^{(1)}|H^{(2)})W_O \in \mathbb{R}^{3 \times 4}.$$

Multi-Head Attention

$$\text{MultiHead}(Q, K, V) = \begin{bmatrix} 2.000 & 1.000 & 1.000 & 1.000 \\ 1.670 & 1.330 & 1.670 & 0.330 \\ 1.102 & 1.898 & 1.102 & 1.747 \end{bmatrix} \begin{bmatrix} 1.000 & 0.000 & 0.000 & 0.000 \\ 0.000 & 1.000 & 0.000 & 0.000 \\ 0.000 & 0.000 & 1.000 & 0.000 \\ 0.000 & 0.000 & 0.000 & 1.000 \end{bmatrix}$$

Resultado final:

Multi-Head Attention (novos *embeddings* contextualizados)

$$\text{Attention}(Q, K, V) = \begin{bmatrix} \text{Life} \\ \text{is} \\ \text{awesome} \end{bmatrix} = \begin{bmatrix} 2.000 & 1.000 & 1.000 & 1.000 \\ 1.670 & 1.330 & 1.670 & 0.330 \\ 1.102 & 1.898 & 1.102 & 1.747 \end{bmatrix}$$

```
1 # -----
2 # Cada camada N da rede neural receberá um módulo de atenção multi-cabeças definido da seguinte forma:
3 # -----
4 self$MM <- torch::nn_module_list(lapply(1:N_Layers,
5   function(x) torch::nn_multihead_attention(
6     n_embd,          # d_model: dimensão do vetores de embedding
7     N_Head,          # h: número de cabeças
8     dropout = p0,    # tecnica para reduzir o overfitting
9     batch_first = TRUE))) # informa a disposição dos dados à biblioteca torch
```

Listing 1: Definição dos blocos de multi-head attention treináveis

```
1 # -----
2 # Cria uma matriz TxT, sendo T = número de tokens na sequência de entrada
3 # Garante que será tratado no mesmo device que X (CPU ou GPU) para que eles possam ser operados juntos
4 # Aplica 1 à diagonal superior, transforma 1 em booleano TRUE para que a biblioteca torch saiba quais
5 # posições precisam ser mascaradas
6 # -----
7 wei <- torch::torch_triu(
8   torch::torch_ones(T, T, device = x$device),
9   diagonal = 1)$to(dtype = torch::torch_bool())
```

Listing 2: Definição da Máscara causal

```
1 for (j in 1:self$N) {
2
3   # -----
4   # 1) Pré-normalização (LayerNorm)
5   #   Normalização dos embeddings, já que todos embeddings interagirão com todos os outros.
6   #   A normalização não altera a informação e estabiliza o treinamento.
7   # -----
```

```

8 QKV <- self$scale1[[j]](output)
9
10 # -----
11 # 2) Chamada da função Multi-Head Self-Attention mascarada do torch que calcula Q, K e V internamente a
    partir de QKV.
12 # -----
13 attn_out <- self$MM[[j]](
14   query      = QKV,      # Input para o cálculo de Q
15   key        = QKV,      # Input para o cálculo de K
16   value      = QKV,      # Input para o cálculo de V
17   attn_mask  = wei,      # Máscara causal
18   need_weights = FALSE   # Dispensa o retorno dos pesos utilizados no cálculo da média ponderada
19 )[[1]]                  # Guarda apenas o resultado da média ponderada, mas não os pesos
20
21 # -----
22 # 3) Conexão residual após atenção
23 # Mantém a informação original dos embeddings e evita que a transformação da atenção distorça
    excessivamente a representação.
24 # Estabiliza o fluxo do gradiente.
25 # -----
26 output <- output + attn_out
27
28 # -----
29 # 4) Feed-Forward Network + residual
30 # Aplicação de uma MLP ponto-a-ponto em cada token individualmente, capturando relações não lineares
    permitindo que a rede aprenda padrões complexos.
31 # Mantendo o resíduo e aplicando a normalização para estabilizar a operação.
32 # -----
33 output <- output + self$FFN[[j]]( self$scale2[[j]](output) )
34 }

```

Listing 3: **Cálculo** da atenção multi-cabeças mascarada em cada camada

Questão 02: Treine um modelo de linguagem com dimensão embedding de 128, duas camadas e duas cabeças para os dados de Shakespeare.

Descrição do experimento e configuração do modelo

Corpus utilizado

O modelo foi treinado sobre um corpus textual extraído da edição completa das obras de William Shakespeare disponibilizada pelo *Project Gutenberg*, um repositório digital que distribui gratuitamente obras que já se encontram em domínio público, contendo todo o conteúdo produzido pelo autor: peças teatrais, poemas narrativos, sonetos, trechos introdutórios e notas editoriais presentes na edição digital, com aproximadamente 5,4 milhões de caracteres.

DUKE.
So that, from point to point, now have you heard
The fundamental reasons of this war,
Whose great decision hath much blood let forth,
And more thirsts after.

FIRST LORD.
Holy seems the quarrel
Upon your Grace's part; black and fearful
On the opposer.

DUKE.
Therefore we marvel much our cousin France
Would, in so just a business, shut his bosom
Against our borrowing prayers.

MENECRATES.
We, ignorant of ourselves,
Beg often our own harms, which the wise powers
Deny us for our good; so find we profit
By losing of our prayers.

POMPEY.
I shall do well.
The people love me, and the sea is mine;
My powers are crescent, and my auguring hope
Says it will come to th' full. Mark Antony
In Egypt sits at dinner, and will make
No wars without doors. Caesar gets money where
He loses hearts. Lepidus flatters both,
Of both is flattered; but he neither loves
Nor either cares for him.

Figura 1: Trechos do corpus utilizado no experimento, provenientes da obra completa de Shakespeare disponibilizado pelo Projeto Gutenberg.

Vocabulário extraído do corpus

O modelo foi treinado no regime *character-level*, o primeiro passo consistiu em extrair todos os caracteres distintos presentes no arquivo `Shakespeare.txt`. Inclui letras maiúsculas e minúsculas, dígitos, pontuação, símbolos especiais, acentos, quebras de linha e espaços.

O vocabulário final contém **109 tokens**, sendo o primeiro reservado para o símbolo especial `<PAD>` utilizado em operações internas. Segue o conjunto de caracteres identificados:

[1]	"<PAD>"	" "	"\t"	"\n"	"\r"	" "	"_"	"_"	"_"	" ,"	" ;"	" :"
[13]	" !"	" ?"	" ."	" ..."	" ' "	" ' "	" ' "	" ' "	" ' "	" ("	")"	" ["
[25]	"]"	" *"	" /"	" &"	" #"	" %"	" •"	" \$"	" 0"	" 1"	" 2"	" 3"
[37]	" 4"	" 5"	" 6"	" 7"	" 8"	" 9"	" a"	" A"	" à"	" À"	" â"	" æ"
[49]	" Æ"	" b"	" B"	" c"	" C"	" ç"	" Ç"	" d"	" D"	" e"	" E"	" é"
[61]	" É"	" è"	" È"	" ê"	" F"	" f"	" G"	" g"	" H"	" h"	" i"	" I"
[73]	" Î"	" j"	" J"	" k"	" K"	" l"	" L"	" m"	" M"	" n"	" N"	" o"
[85]	" O"	" œ"	" p"	" P"	" q"	" Q"	" r"	" R"	" s"	" S"	" t"	" T"
[97]	" ù"	" u"	" U"	" v"	" V"	" w"	" W"	" x"	" X"	" y"	" Y"	" z"
[109]	" Z"											

Figura 2: Vocabulário extraído no corpus utilizado (obra completa de Shakespeare).

Hiperparâmetros do modelo

Os hiperparâmetros utilizados no modelo são:

Tabela 1: Hiperparâmetros utilizados no modelo GPT treinado.

Hiperparâmetro	Valor	Descrição
block_size	50	contexto máximo (janela do attention).
n_embd	128	dimensão dos embeddings.
N_Layers	2	número de blocos Transformer.
N_Head	2	número de cabeças de atenção.
dropout	0.2	regularização.
learning_rate	0.003	taxa de aprendizado.
batch_size	64	tamanho do mini-batch.
epochs	1200	número total de épocas.

O tamanho de contexto (`block_size` = 50) limita o alcance da atenção foi ajustado empiricamente para conseguir captar o estilo do texto e ao mesmo tempo ser viável para ser treinado em hardware pessoal. A dimensão dos vetores de embedding (`n_embd` = 128) é significativo, mas combinada ao número reduzido de camadas e a utilização de múltiplas cabeças de atenção (`N_Layers` = 2, `N_Head` = 2), mantém o modelo ágil e compacto, suficiente para capturar regularidades sintáticas e estilísticas do texto. O dropout (0.2) fornece regularização. A taxa de aprendizado escolhida (0.003) foi ajustada empiricamente.

Arquitetura e fluxo do modelo

A arquitetura utilizada neste trabalho segue o padrão dos modelos GPT do tipo *decoder-only*, cujo fluxo computacional está ilustrado na Fig. 3. O processamento inicia-se pela soma entre o embedding dos tokens e o embedding posicional aprendido, resultando em uma representação contínua que preserva a ordem sequencial do texto. Em seguida, cada camada Transformer aplica uma normalização prévia (*LayerNorm*) seguida de um bloco de autoatenção multi-cabeças mascarada, garantindo o comportamento autoregressivo: o modelo só pode utilizar informações de tokens passados para prever o próximo token.




Figura 3: Arquitetura geral do modelo GPT utilizado no experimento.

O resultado da atenção é então somado à entrada original por meio de uma conexão residual, estabilizando o fluxo de gradientes. Após isso, uma nova normalização é aplicada antes do bloco *feed-forward* ponto-a-ponto, responsável por expandir e recomprimir a dimensionalidade interna, permitindo ao modelo capturar não-linearidades locais. Esse bloco também é seguido por uma conexão residual, completando a estrutura *pré-norm* típica de arquiteturas modernas de Transformers. Ao final das camadas empilhadas (2) uma projeção linear — equivalente ao uso do embedding transposto — produz os logits sobre o vocabulário, posteriormente convertidos em probabilidades via *softmax*, que indica o próximo token mais provável.

Tamanho do modelo

O modelo GPT implementado apresenta um total de **418 866 parâmetros** treináveis, distribuídos entre embeddings, projeções lineares das camadas de atenção, normalizações e redes feed-forward. A Tabela 2 apresenta o detalhamento dos tensores de parâmetros que compõem o modelo.

Parâmetro	Dimensão	Nº de parâmetros
wpe.weight	50×128	6 400
wte.weight	109×128	13 952
MM.0.in_proj_weight	384×128	49 152
MM.0.in_proj_bias	384	384
MM.0.out_proj_weight	128×128	16 384
MM.0.out_proj_bias	128	128
MM.1.in_proj_weight	384×128	49 152
MM.1.in_proj_bias	384	384
MM.1.out_proj_weight	128×128	16 384
MM.1.out_proj_bias	128	128
scale1.{0,1}.weight	128	$128 + 128$
scale1.{0,1}.bias	128	$128 + 128$
scale2.{0,1}.weight	128	$128 + 128$
scale2.{0,1}.bias	128	$128 + 128$
scale3.weight	128	128
scale3.bias	128	128
FFN.0.{0,2}.weight	512×128	$65\,536 + 65\,536$
FFN.0.{0,2}.bias	512	$512 + 128$
FFN.1.{0,2}.weight	512×128	$65\,536 + 65\,536$
FFN.1.{0,2}.bias	512	$512 + 128$
ln_f.weight	109×128	13 952
Total	—	418 866

Tabela 2: Parâmetros treináveis do modelo GPT utilizado no experimento.

Treinamento e métricas

No treinamento, foi utilizada a função de perda *cross-entropy*, computada entre os logits produzidos pelo modelo e os caracteres-alvo da sequência. A cada época, foi registrado tanto a perda de treino quanto a de teste, permitindo acompanhar a evolução do aprendizado e o possível surgimento de sobreajuste.




Figura 4: Evolução da função de perda durante o treinamento: comparação entre as curvas de treino e de teste ao longo das 1200 épocas.

As curvas de perda apresentaram comportamento regular ao longo das épocas: as perdas de treino e de teste permaneceram próximas, decrescendo de forma suave sem indícios de divergência. Essa proximidade entre as curvas indica ausência de sobreajuste, sugerindo que o modelo conseguiu aprender padrões relevantes do corpus sem memorizar o conjunto de treinamento. Além disso, a estabilidade observada nas últimas épocas reflete um processo de otimização bem-sucedido.

O valor final da perda obtido após 1200 épocas foi de aproximadamente 1.82 para o conjunto de treino e 1.78 para o conjunto de teste.

Resultado

Os resultados obtidos mostram que o modelo, apesar de compacto, aprendeu *padrões estatísticos* presentes no inglês shakespeariano, como a distribuição típica de comprimentos de palavras, certa cadência rítmica, alternância entre diálogos e rubricas, além da reprodução aproximada de construções sintáticas características do período.

Entretanto, o texto gerado permanece semanticamente incoerente, apresentando repetições excessivas e sentenças circulares. Esse comportamento é esperado para um modelo de pequena escala: ele captura a superfície do estilo, mas não reproduz a coerência e os encadeamentos semânticos ao longo do texto. Uma sugestão para testes futuros é que um processo de tokenização mais robusto poderá contribuir para melhorar a coerência do texto.

Anter to my lord, and to the with and the world with that to
they have a man they seen of the cannother with a shall he
have the with a sons to the can the wittle the would the will
have the come to the would
To the can too to the world to me the coment too the with the
comman the will have the come to my like the with the would
the conself the with to the come an the words,
And the words, an a shall the coment on the can to that the
can the will to me the can a man the come and when they
senders.
[_Exeunt._]
PETHARD.
The he will they have they have with the confather the cannot
the will the come the word and with the can and that which the

SENE ONT. A me that the so a course that to the came and to
thee, the compe thee, and me seat the come that the so a me,
and to me to the come the so to man that to make the come,
that the word a come a so the see the see a man the come
the course and the so to the see and me so the see a praint.

SENE.
So me, the we the come to the sear a part the some a praith,
the with a proust and that the can the some a mand to the
counted the some, the counders a me see that that me see to
that to man to thee with to that my so the came and that thee
word,
Then, and with to me,
And me, the so all we with a cand man a part the see, and
that and with a me to me the camine the seak to the will make
to to to making too a me so that that me so a can the so to me
to man the can the so a come the so the come a part and the
see the course the so a care, and the so the come a me, |

Figura 5: Trechos do texto gerado pelo modelo treinado.

O experimento valida a implementação completa de um Transformer do tipo *decoder-only*, confirmando que mesmo arquiteturas reduzidas conseguem capturar características linguísticas relevantes quando treinadas sobre um corpus particular. O modelo foi capaz de replicar com consistência o *ritmo*, o *fluxo* e a *forma* geral do estilo shakespeariano.

Questão 03: Repita o item anterior sem o mecanismo de atenção (com múltiplas cabeças) e descreva o que ocorre no treinamento.